

Matematički fakultet
Univerzitet u Beogradu

Klasifikacija i klaster analiza ishoda lečenja pacijenata na intenzivnoj nezi (ICU)

Autori:

Aleksandar Ilić 80/2021

Nikola Živković 108/2021

Sadržaj

1. Uvod.....	2
2. Skup podataka	3
3. Preprocesiranje podataka.....	3
3.1 Obrada nedostajućih vrednosti	4
3.2 Standardizacija podataka.....	4
3.3 Podela na trening i test skup.....	4
4. Redukcija dimenzionalnosti	4
5. Algoritmi i metrike	5
6. Klasifikacija	5
6.1 Napomena o metrikama	6
6.2 Uticaj redukcije dimenzionalnosti.....	6
6.3 Najbolja konfiguracija po modelu.....	6
6.4 Analiza i poređenje.....	6
7. Klasterovanje.....	6
7.1 Rezultati	7
7.2 Analiza	7
7.3 Napomena o Spectral clustering-u	7
8. Diskusija.....	8
9. Zaključak.....	8

1. Uvod

U ovom radu primenjene su tehnike klasifikacije i klasterovanja nad skupom kliničkih ICU podataka.

Klasifikacija - nadgledano predviđanje binarnog ishoda (preživljavanje ili smrtni ishod).

Klasterovanje - nenadgledano grupisanje pacijenata na osnovu kliničkih atributa.

Cilj je primeniti i uporediti više algoritama, kao i ispitati uticaj načina pripreme podataka (redukcije dimenzionalnosti) i izražene neizbalansiranosti klasa.


2. Skup podataka

Skup sadrži 3600 pacijenata opisanih sa 120 kolona. Nakon uklanjanja identifikatora recordid ostaje 119 atributa. Atributi su kliničke prirode i obuhvataju demografske podatke (Age, Gender, Height, Weight), tip jedinice intenzivne nege (CCU, CSRU, SICU), kliničke skorove (SAPS-I, SOFA) i statistike vitalnih parametara i laboratorijskih nalaza tokom boravka (broj trombocita, troponin I/T, leukociti, pH, trajanje mehaničke ventilacije, ukupan izlaz urina), date u varijantama _first, _last, _median.

	recordid	SAPS-I	SOFA	Age	Gender	Height	Weight	CCU	CSRU	SICU	...	Platelets_last	TroponinI_last	TroponinT_last	WBC_last	Weight_last	pH_last	MechVentStartTime
0	137517	-1	2	56.0	0.0	NaN	79.6	0	0	0	...	444.0	NaN	NaN	7.3	79.6	NaN	NaN
1	145680	10	3	72.0	1.0	NaN	70.0	0	0	0	...	82.0	NaN	0.07	2.4	70.0	7.48	NaN
2	138649	-1	8	81.0	0.0	NaN	NaN	0	0	0	...	211.0	NaN	NaN	7.0	NaN	NaN	NaN
3	149075	16	8	56.0	1.0	180.3	94.8	1	0	0	...	204.0	NaN	NaN	11.4	98.9	7.44	1128.0
4	141408	14	7	52.0	1.0	182.9	120.6	0	1	0	...	352.0	NaN	NaN	9.0	120.6	7.43	143.0

5 rows × 120 columns

Ciljna promenljiva In-hospital_death je binarna (0 = pacijent preživeo, 1 = smrtni ishod). Klase su izrazito neizbalansirane: odnos negativne prema pozitivnoj klasi iznosi približno 86 : 14, tj. smrtni ishod čini oko 14% uzoraka.



3. Preprocesiranje podataka

3.1 Obrada nedostajućih vrednosti

Nedostajuće vrednosti postoje u 112 kolona; najviše ih imaju retki laboratorijski nalazi (troponin I ~66%, holesterol ~64%, troponin T ~55%). Kolone nisu odbacivane: kod medicinskih nalaza izostanak vrednosti nije slučajna, redak nalaz se najčešće radi ciljano, po lekarskoj sumnji, pa i sama činjenica da je urađen nosi informaciju. Zato su nedostajuće vrednosti zamenjene medijanom (izračunatom na trening skupu), uz dodavanje indikatorskih kolona `_missing` za nalaze sa preko 60% nedostajućih vrednosti, koje čuvaju informaciju o tome da li je nalaz uopšte postojao. Medijana je izabrana jer aritmetička vrednost nema mnogo smisla u kontekstu medicinskih podataka koji se obrađuju.

```
TroponinI_last      0.66
TroponinI_first     0.66
Cholesterol_first   0.64
Cholesterol_last    0.64
TroponinT_first     0.55
...
HCT_last            0.01
HCO3_last           0.01
Platelets_last      0.01
Temp_median         0.01
Na_last             0.01
Length: 112, dtype: float64
```

Udeo nedostajućih vrednosti po kolonama.

3.2 Standardizacija podataka

Pošto atributi imaju različite opsege, a i planirana je redukcija dimenzionalnosti pomoću PCA, izvršena je standardizacija (oduzimanje srednje vrednosti i deljenje standardnom devijacijom, iz statistike trening skupa). Ovaj korak je važan za sve metode koje koriste rastojanje kao meru sličnosti.

3.3 Podela na trening i test skup

Podaci su podeljeni u odnosu 70:30 uz stratifikaciju po ciljnoj promenljivoj, kako bi udeo smrtnih ishoda bio isti u oba skupa. Rezultujuće veličine su 2520 (trening) i 1080 (test) uzoraka.

4. Redukcija dimenzionalnosti

Standardizovani skup ima veliki broj atributa (123, uključujući indikatorske kolone), pa je primenjena analiza glavnih komponenti (PCA). PCA transformiše attribute u nove, međusobno ortogonalne komponente koje zadržavaju što veći deo varijanse. Pripremljene su tri reprezentacije koje se dalje porede:

- **Bez PCA** - pun standardizovan skup atributa (123 kolone);
- **PCA 95%** - glavne komponente koje objašnjavaju 95% varijanse: **74** komponente;
- **PCA 50** - prvih **50** glavnih komponenti.

Izbor praga od 95% potvrđen je pomoćnim eksperimentom: logistička regresija na PCA-90% (59 komponenti) i PCA-95% (74 komponente) dala je bliske rezultate, uz blago bolju F1-meru za 95% (0,415 naspram 0,403). Kod neizbalansiranih klasa F1 bolje odražava kvalitet predikcije obe klase, pa je izabrana ta reprezentacija.

5. Algoritmi i metrike

Za problem klasifikacije primenjeno je pet algoritama:

- Ridge Classifier
- Linear Discriminant Analysis (LDA)
- Random Forest
- XGBoost
- Multilayer Perceptron (MLP)

Za problem klasterovanja primenjeno je pet algoritama:

- Gaussian Mixture Model (GMM)
- BIRCH
- OPTICS
- Spectral clustering
- HDBSCAN

Hiperparametri za klasifikacione modele birani su optimizacijom **F1-mere** kroz GridSearchCV i RandomizedSearchCV unakrsnu validaciju (cv = RepeatedStratifiedKFold sa 5 podela × 3 ponavljanja, osim za RandomForest gde je cv = 5). Zbog neizbalansiranosti korišćeni su parametri class_weight='balanced' (Ridge, LDA, Random Forest), scale_pos_weight (XGBoost) i oversampling **SMOTE** (MLP). Kvalitet klasterovanja meren je **silhouette** koeficijentom (opseg -1 do 1, veće je bolje) za GMM, BIRCH i **Spectral**, za gustinske metode (OPTICS, HDBSCAN), kod kojih silhouette nije informativan, praćen je **udeo šuma** (noise_ratio, udeo tačaka koje ne pripadaju nijednom klasteru).

6. Klasifikacija

6.1 Napomena o metrikama

Zbog neizbalansiranosti, tačnost je varljiva metrika: trivijalni model koji sve pacijente proglasi preživelim postiže tačnost od oko **88,4%**. Zato se kvalitet ocenjuje prvenstveno kroz **F1-meru** i **odziv (recall)** za klasu smrtnog ishoda u kliničkom kontekstu, propustiti rizičnog pacijenta obično je skuplje od lažne uzbune.

6.2 Uticaj redukcije dimenzionalnosti

Model	Bez PCA	PCA 95%	PCA 50
Ridge Classifier	0,488	0,479	0,472
LDA	0,507	0,497	0,466
Random Forest	0,492	0,477	0,485
XGBoost	0,517	0,468	0,493
MLP	0,492	0,489	0,421

Tabela 1. F1-mera na test skupu po modelu i reprezentaciji podataka. Za svih pet modela najbolji rezultat daje reprezentacija bez PCA.

Za svaki model pun (standardizovan) skup obeležja daje najveću F1-meru, dok PCA, naročito na 50 komponenti, uglavnom blago pogoršava rezultat (kod MLP-a osetno, pad na 0,421). Redukcija dimenzionalnosti ovde donosi brzinu, ali ne i bolji kvalitet klasifikacije.

6.3 Najbolja konfiguracija po modelu

Model	Verzija	Tačnost	Preciznost	Odziv	F1
Ridge Classifier	Bez PCA	0,779	0,361	0,755	0,488
LDA	Bez PCA	0,865	0,517	0,497	0,507
Random Forest	Bez PCA	0,819	0,404	0,629	0,492
XGBoost	Bez PCA	0,820	0,414	0,689	0,517
MLP	Bez PCA	0,828	0,419	0,596	0,492

Tabela 2. Metrike na test skupu za najbolju reprezentaciju svakog modela; istaknut je XGBoost sa najboljom F1-merom.

6.4 Analiza i poređenje

- **XGBoost** daje najbolju F1-meru (0,517) i visok odziv (0,689), najbolji kompromis između otkrivanja smrtnih ishoda i broja lažnih uzbuna.
- **LDA** postiže najveću tačnost (0,865) i najuravnoteženiju preciznost/odziv (0,517 / 0,497), ali konzervativno predviđa manje smrtnih ishoda i promašuje otprilike polovinu stvarnih slučajeva.
- **Ridge Classifier** ima najveći odziv (do 0,755) uz najnižu preciznost (0,361) i tačnost (0,779), označava mnogo pacijenata kao rizične, pa je koristan kao osetljiv skrining.
- **Random Forest** i **MLP** su u sredini ($F1 \approx 0,49$), bez izražene prednosti.
- Vrednosti F1 iz unakrsne validacije ($\approx 0,45-0,50$) i sa test skupa ($\approx 0,47-0,52$) su bliske, što ukazuje da nema izraženog preprilagođavanja.

7. Klasterovanje

Za razliku od klasifikacije, klasterovanje ne koristi oznaku ishoda, cilj je otkriti prirodne grupe pacijenata. Primenjeno je pet algoritama, uz vizuelizaciju u UMAP prostoru (obojenu po klasterima i po ishodu).

Rezultati su podeljeni u dve grupe: particione i model-bazirane metode (ocena silhouette koeficijentom) i gustinske metode (ocena udelom šuma).

7.1 Rezultati

Algoritam	Verzija	Broj klastera	Veličine klastera	Silhouette
GMM	PCA 95%	2	1009 / 2591	0,161
GMM	Bez PCA	2	2570 / 1030	0,155
GMM	PCA 50	2	965 / 2635	0,176
BIRCH	PCA 95%	2	1459 / 2141	0,056
BIRCH	Bez PCA	2	1714 / 1886	0,037
BIRCH	PCA 50	2	1368 / 2232	0,065
Spectral	PCA 95%	2	3568 / 32	0,316*
Spectral	Bez PCA	2	3565 / 35	0,304*
Spectral	PCA 50	2	3564 / 34	0,324*

Tabela 3. Particione i model-bazirane metode (ocena: silhouette); istaknut je najbolji **smisleni** rezultat (GMM, PCA 50). Spectral daje degenerisanu podelu (jedan klaster i jedna izolovana tačka), pa je njegov silhouette artefakt zavaravajuć

Gustinske metode se ocenjuju udelom šuma (noise_ratio - udeo tačaka označenih kao šum); niži udeo je bolji, a visok udeo znači odsustvo gustih, razdvojenih regiona:

Algoritam	Verzija	Broj klastera (bez šuma)	noise_ratio
OPTICS	PCA 95%	2	0,856
OPTICS	Bez PCA	2	0,868
OPTICS	PCA 50	2	0,869
HDBSCAN	PCA 95%	2	0,918
HDBSCAN	Bez PCA	2	0,920
HDBSCAN	PCA 50	2	0,908

Tabela 4. Gustinske metode (ocena: noise_ratio). U svim slučajevima 86-92% tačaka je proglašeno šumom, uz svega dva sitna gusta „džepa“.

7.2 Analiza

- **GMM (0,155-0,176) je osetno bolji od BIRCH-a (0,037-0,065).** Meke, eliptične Gausove komponente bolje opisuju preklapajuće raspodele nego particionisanje BIRCH-a zasnovano na pragu. Najbolji rezultat u celom radu daje GMM na PCA-50 (silhouette 0,176), ali je i to niska vrednost, koja ukazuje na slabu razdvojenost.
- **Spectral** nije dao upotrebljivu podelu: u sve tri reprezentacije jedan klaster sadrži ≈ 3565 tačaka, a drugi ≈ 34 . Visok silhouette ($\approx 0,3$) je posledica malog broja izolovanih tačaka, a ne stvarne strukture.
- **Gustinske metode (OPTICS i HDBSCAN) izdvajaju 86-92% tačaka kao šum** i nalaze samo dva sitna gusta „džepa“ (po 150-260 tačaka). Visok noise_ratio je jasan znak da ne postoje gusti, međusobno razdvojeni regioni.
- Sve metode se slažu: podaci čine jednu široku, kontinuiranu strukturu bez prirodno razdvojenih grupa. Klasteri koje particione metode nalaze najverovatnije odgovaraju širokim profilima pacijenata, a ne čistoj podeli na preživele i preminule.

7.3 Napomena o Spectral clustering-u

Spectral je pokrenut sa afinitetom nearest_neighbors, a izbor najboljeg rešenja vođen je najvišom silhouette vrednošću. U podacima bez izražene strukture taj kriterijum je „nagradio“ degenerisano rešenje, algoritam je izdvojio mali broj tačaka u zaseban klaster, čime silhouette veštački raste, iako preostale tačke čine jednu

grupu. Zato vrednosti za Spectral iz Tabele 3 ne treba tumačiti kao dobar rezultat. Ovaj primer ilustruje širu pouku: silhouette sam po sebi može favorizovati degenerisana rešenja, pa uz njega treba pratiti i veličine klastera.

8. Diskusija

Rezultati pokazuju da u ovom skupu postoji upotrebljiv, ali umeren signal za predikciju smrtnosti (najbolja $F1 \approx 0,52$), dok nijedan od pet algoritama klasterovanja ne otkriva izraženu strukturu: particione metode daju samo dva široka klastera sa niskim silhouette-om (najviše 0,18 kod GMM-a), Spectral daje degenerisanu podelu (veštački visok silhouette), a gustinske metode (OPTICS, HDBSCAN) 86-92% tačaka proglašavaju šumom. Ova suprotnost sugerise da smrtnost zavisi od kombinacije obeležja (granice odlučivanja), a ne od pripadnosti prirodno razdvojenim grupama pacijenata. Zanimljivo je i da redukcija dimenzionalnosti nije popravila ni klasifikaciju ni klasterovanje, pun standardizovan prostor atributa pokazao se bolje od redukovanih.

9. Zaključak

Sprovedena je uporedna analiza pet klasifikacionih i pet algoritama klasterovanja nad ICU skupom, uz tri reprezentacije podataka. U klasifikaciji je reprezentacija bez PCA dosledno davala najbolju F1-meru, a najkvalitetniji model je XGBoost ($F1 = 0,517$, odziv = 0,689); LDA nudi najveću tačnost, a Ridge Classifier najveći odziv. U klasterovanju najbolji (iako slab) rezultat daje GMM (silhouette 0,176), BIRCH je slabiji, Spectral daje degenerisanu podelu, a gustinske metode pokazuju visok udeo šuma. Svih pet potvrđuje da skup nema jasno razdvojene grupe.